Avaliação de modelos de *deep-learning* para detecção de embarcações em áreas marinhas protegidas a partir de imagens ópticas de satélite

Rodrigo Sant'Ana & Letícia Zorzi Rama

2026-04-07

Índice

1 Contextualização **1**

2 Objetivos **2**
2.1 Objetivo Geral 2
2.2 Objetivos Específicos 2

3 Abordagem Metodológica Proposta **3**
3.1 Fonte de dados 3
3.2 Compilação de dados a partir das fontes abertas 3
3.3 Compilação de dados a partir de fontes pagas 4

4 Análise Exploratória de Dados **4**
4.1 Áreas e épocas das atividades de pesca de interesse 4

5 Desenvolvimento dos Modelos **5**

Referências **5**

1 Contextualização

A inteligência artificial vem sendo progressivamente incorporada na detecção de embarcações de pesca em Áreas Marinhas Protegidas (Welch et al., 2024). Isso se evidencia na proliferação de modelos de visão computacional desenvolvidos com algoritmos de aprendizado profundo para a detecção de objetos com imagens ópticas de satélite (Wang et al., 2025). Com múltiplas camadas, tais algoritmos aprendem diretamente dos dados, tornando-se eficazes no reconhecimento de padrões complexos (LeCun et al., 2015; Goodfellow et al., 2016; Glassner, 2021; Zhang et al., 2023). Por isso, ao aprendizado

profundo se atribuem avanços na resolução de problemas desafiadores, incluindo os de visão computacional (Szeliski, 2022).

Esses avanços se refletem diretamente no sensoriamento remoto, um campo fértil para a visão computacional (Savelonas et al., 2022). Entre as tarefas, destaca-se a detecção orientada de objetos, sendo embarcações uma categoria recorrentemente explorada na literatura científica (Zhao et al., 2024) e o monitoramento da pesca uma das motivações (Liang, 2025). Por isso, inovações advindas dessa interseção entre aprendizado profundo, visão computacional e sensoriamento remoto vêm sendo incorporadas nos mecanismos internacionais de gestão pesqueira e conservação da biodiversidade marinha conhecidos como Áreas Marinhas Protegidas (Gerhardinger et al., 2011) as quais já fazem uso histórico do sensoriamento remoto (Kachelriess et al., 2014). Em 2018, o Brasil decretou como Áreas Marinhas Protegidas tanto o arquipélago de São Pedro e São Paulo quanto as ilhas da Trindade e o arquipélago Martin-Vaz (Soares e Lucas, 2018). Este mosaico, conhecido como Grandes Unidades Oceânicas (Souza Junior, 2021), registra a pesca ilegal, não regulamentada e não reportada (IUU) (Francini-Filho et al., 2018; Pinheiro, 2018), um dos desafios globais na gestão dessas áreas (Iacarella et al., 2021; Grey et al., 2023). Como mecanismo de gestão, realizam-se operações de fiscalização, monitoramento e controle com dados de posicionamento, baseadas em sistemas que ainda permitem pontos cegos. Cenários assim incitam soluções com inteligência artificial, capazes de integrar dados de sensoriamento remoto em sistemas mais transparentes para a detecção de embarcações de pesca a partir de imagens ópticas de satélite (Welch et al., 2024).

2 Objetivos

2.1 Objetivo Geral

Avaliar a performance de modelos de aprendizado profundo para a detecção orientada de embarcações de pesca em Áreas Marinhas Protegidas, a partir de imagens ópticas de satélites.

2.2 Objetivos Específicos

a) Compilar uma base de dados para treinamento e teste dos algoritmos;
b) Propor um pipeline para implementação e avaliação dos algoritmos;
c) Avaliar algoritmos de aprendizado profundo para detectar embarcações de pesca a partir de imagens de ópticas satélite de diferentes resoluções e sensores;
d) Consolidar uma ferramenta iterativa para avaliação dos resultados, além de sua divulgação à comunidade em geral.

3 Abordagem Metodológica Proposta

3.1 Fonte de dados

Como fonte inicial de informações serão compilados dados (e.g. imagens de satélite) de fontes publicas, tais como:

- Google Earth Engine;
- Google Earth Pro.

Adicionalmente, será buscado aquisitar imagens de satélite a partir de empresas dedicadas ao fornecimento deste tipo de serviço. Por exemplo, Vantor, Planet, Airbus, entre outras.

Como forma de explorar sinergias, o primeiro foco de contato está sendo com a Airbus, pois a Vantor já está sendo contatada pela Profa. Marie Ruffener da UFRN. Adicionalmente, será buscado contato novamente com a Planet, como forma de exaurir potenciais coberturas de dados satelitais.

Ainda neste sentido, como forma de ampliar as bases que serão utilizadas para treino do algoritmo, duas estratégias adicionais serão buscadas:

- Utilizar parte ou uma mixagem das bases de dados compiladas e derivadas do levantamento sistemático da literatura;
- Coletar dados a partir de sobrevoo com drone na área portuária do complexo de empresas pesqueiras de Itajaí e Navegantes.

3.2 Compilação de dados a partir das fontes abertas

Para a compilação de dados a partir das fontes abertas (e.g. Google Earth Engine e Google Earth Pro) a abordagem de coleta será definida da seguinte forma:

a) Identificação de portos pesqueiros marinhos do Brasil a partir de fontes secundárias como MPA, MMA, GFW, LEMA;
b) Busca por identificação destes portos a partir das bases de imagens satelitais gratuítas;
c) Exportação das imagens com a melhor resolução possível a partir da identificação de embarcações nas seções observadas dos mesmos. E, neste sentido, para reduzir da melhor forma possível a subjetividade do processo, as etapas abaixo devem ser seguidas:

   c.1) A coleta das imagens deverá ser realizada sempre pelo(a) mesmo(a) especialista. Reduzindo assim o viés de amostrador;

   c.2) Os meta-dados devem ser armazenados em banco de dados textual, dentre as informações coletadas devem estar, sempre que possível, a data da coleta, a data da imagem, o município da imagem, a UF da imagem, a altitude referente a zoom definido no momento da exportação, a classificação da imagem (Oceano | Porto | Misto), o nome do arquivo da imagem, a fonte dos dados;

   c.3) Para definição do máximo zoom, o(a) especialista deve definir o momento ligeiramente anterior a extrapolação do pixel;

d) Adicionalmente, para melhor detecção de zonas no Oceano aberto onde ocorrem as atividades de pesca de interesse do projeto informações do GFW e/ou PMAP-SC serão utilizadas como forma a definir áreas e épocas de busca.

3.3 Compilação de dados a partir de fontes pagas

Por se tratar de um custo relativamente alto, as compras de imagens deverão ser mais certeiras, a proposta é aquisitar imagens da zona costeira, portos e adjacências, visando assim maximizar as fontes de informações disponíveis para treino dos modelos. Adicionalmente, busca-se maximizar a sinergia entre projetos CI-BNA e CNPq.

Para melhor estruturar a rotina de coleta de dados a partir destas fontes, para os ambientes oceânicos serão utilizadas informações base que permitam a identificação de áreas e épocas em que as atividades de pesca ocorrem. Para isto serão utilizados dados do GFW.

A partir destas informações, deverá ser buscada imagens que compatibilizem-se com os locais e épocas identificados como zonas de frequência de observação de embarcações operando. Com isto, será possível determinar quais embarcações, petrechos, épocas e áreas estão sendo utilizadas. Potencializando, não somente a identificação de imagens que apresentem atividades de pesca, como também, possíveis implementações de validações cruzadas para aferição da qualidade dos modelos desenvolvidos.

4 Análise Exploratória de Dados

4.1 Áreas e épocas das atividades de pesca de interesse

Compilar uma base de dados para treinamento e teste dos algoritmos (objetivo específico (a)) é um objetivo que irá se decompor em atividades hierarquicamente estruturadas. Uma das atividades será a análise explotarória de dados para se definir áreas e épocas de busca das imagens de satélite. Áreas e épocas de busca são necessárias para maximizar a chance de se encontrar imagens ópticas de satélite, de alta resolução, com embarcações pesqueiras presentes em zonas do Oceano aberto onde ocorrem as atividades de pesca de interesse do projeto.

Para que áreas e épocas de busca sejam definidas, será preciso descobrir padrões históricos de ocorrência de embarcações de pesca cujas operações incluem áreas no entorno das Grandes Unidades Oceânicas. A descoberta de padrões de ocorrência implicará na coleta de dados históricos de fontes como o GFW e o PMAP-SC. Durante a coleta será necessário conhecer os dados disponibilizados pelo GFW e pelo PMAP-SC no sentido de quais são e o que representam no âmbito da ciência pesqueira. A estrutura abaixo representa essa hierarquia:

|_Compilar uma base de dados para treinamento dos algoritmos;

|___Encontrar imagens de satélite, de alta resolução, com embarcações pesqueiras

presentes em zonas do Oceano aberto onde ocorrem as atividades de pesca de interesse;

|____Definir áreas e épocas de busca;

|_____Descobrir padrões históricos de ocorrência de embarcações de pesca cujas operações incluem áreas no entorno das Grandes Unidades Oceânicas;

|_____Analisar exploratória dos dados;

|_____Coletar dados do GFW e do PMAP-SC;

|_____Conhecer os dados disponibilizados pelo GFW e pelo PMAP-SC no sentido de quais são e o que representam no âmbito da ciência pesqueira.

5 Desenvolvimento dos Modelos

A definir...

Referências

Francini-Filho, R. B. et al. (2018). Diagnóstico Biológico e Sócio-Econômico para a proposta de criação de uma Área de Proteção Ambiental e um Monumento Natural Marinho no Arquipélago São Pedro e São Paulo. Brasília: Ministério do Meio Ambiente.

Gerhardinger, L. C. et al. (2011). Marine Protected Dramas: The Flaws of the Brazilian National System of Marine Protected Areas. *Environmental Management* 47, 630–643. doi: 10.1007/s00267-010-9554-7

Glassner, A. S. (2021). *Deep Learning: A Visual Approach*. San Francisco, CA: No Starch Press.

Goodfellow, I., Bengio, Y., e Courville, A. (2016). *Deep Learning*. Cambridge, MA: MIT Press. Disponível em: https://www.deeplearningbook.org

Grey, B. et al. (2023). An investigation into computational methods for classifying fishing vessels to identify illegal, unreported and unregulated fishing activity., em *Proceedings of the International Conference on Computational Intelligence and Applications (ICCIA)*, (Haikou, China: IEEE), 13–20. doi: 10.1109/ICCIA59709.2023.10291874

Iacarella, J. C. et al. (2021). A synthesis of the prevalence and drivers of non-compliance in marine protected areas. *Biological Conservation* 255, 108927. doi: 10.1016/j.biocon.2021.108927

Kachelriess, D. et al. (2014). The application of remote sensing for marine protected area management. *Ecological Indicators* 36, 169–177. doi: 10.1016/j.ecolind.2013.07.003

LeCun, Y., Bengio, Y., e Hinton, G. (2015). Deep learning. *Nature* 521, 436–444. doi: 10.1038/nature14539

Liang, L. (2025). Computer Vision and Deep Learning in Ship Target Detection. *Journal of Computing and Electronic Information Management* 17, 10–14.

Pinheiro, H. T. (2018). Diagnóstico Biológico e Sócio-Econômico para a proposta de criação de uma Área de Proteção Ambiental e um Refúgio de Vida Silvestre na Cadeia Vitória-Trindade. Vitória: Ministério do Meio Ambiente.

Savelonas, M. A. et al. (2022). Computer Vision and Pattern Recognition for the Analysis of 2D/3D Remote Sensing Data in Geoscience: A Survey. *Remote Sensing* 14. doi: 10.3390/rs14235981

Soares, M. O., e Lucas, C. C. (2018). Towards large and remote protected areas in the South Atlantic Ocean. *Marine Policy* 93, 101–103. doi: 10.1016/j.marpol.2018.03.008

Szeliski, R. (2022). *Computer Vision: Algorithms and Applications*. Cham: Springer.

Wang, K. et al. (2025). Oriented object detection in optical remote sensing images using deep learning: A survey. *Artificial Intelligence Review* 58.

Welch, H. et al. (2024). Harnessing AI to map global fishing vessel activity. *One Earth* 7, 1685–1691. doi: 10.1016/j.oneear.2024.09.004

Zhang, A. et al. (2023). *Dive into Deep Learning*. Cambridge: Cambridge University Press.

Zhao, T. et al. (2024). Ship Detection with Deep Learning in Optical Remote-Sensing Images. *Remote Sensing* 16. doi: 10.3390/rs16112015